

PRIMER PARCIAL
SUSTENTACIÓN SEPTIEMBRE 21 DE 2026

El proyecto consiste en desarrollar un sistema completo de gestión y análisis de datos científicos de Física a partir de un conjunto de datos reales obtenido de una fuente científica oficial. Cada estudiante trabajará de manera individual con el tema y conjunto de datos asignado, relacionado con fenómenos como ondas gravitacionales, colisiones de partículas, espectros atómicos, física nuclear, astrofísica estelar, física solar y plasma u otros fenómenos físicos. El propósito es que el estudiante recorra todo el ciclo de transformación de datos científicos, desde la obtención de los datos originales hasta su almacenamiento estructurado, consulta y análisis, integrando Python, Pandas, MySQL, Docker, JupyterLab y DBeaver.

Estudiante	Proyecto / datos	Fuente oficial y descarga	¿Qué contienen los datos?
MARTINEZ AYALA JUAN DIEGO	Ondas gravitacionales	GWOSC – Gravitational Wave Open Science Center	Señales de <i>strain</i> registradas por LIGO/Virgo/KAGRA, eventos, masas, distancia, SNR, detector y tiempo.
JEISON FERNANDO RAMOS LARA	Colisiones de partículas – CERN	CERN Open Data Portal	Eventos de colisiones del LHC, partículas reconstruidas, energía, momento, carga y variables cinemáticas.
ESPITIA GUZMAN LUDER	Espectros atómicos	NIST Atomic Spectra Database	Líneas espectrales de átomos e iones: longitud de onda, energía, intensidad y probabilidades de transición.
LAURA ISABEL NIETO PARROYO	Física nuclear – isótopos	NNDC NuDat 3	Isótopos, niveles energéticos, vidas medias, modos de decaimiento, energías y propiedades nucleares.
OSORIO MARTINEZ KEVIN MATEO	Astrofísica estelar – Gaia DR3	Gaia ESA Archive	Posición, paralaje, movimiento propio, magnitud, velocidad radial y parámetros físicos de millones de estrellas.
SUAREZ SANCHEZ SANTIAGO	Física solar y plasma	NASA CDAWeb	Campo magnético, densidad, temperatura, velocidad del plasma, partículas y viento solar medidos por misiones espaciales.
PEREZ CRIOLLO ANDRES DAVID	Óptica y fotónica	NIST Physical Reference Data – Atomic & Molecular Data	Datos de propiedades ópticas y espectroscópicas de átomos y moléculas: transiciones, longitudes de onda, energías y parámetros de interacción con la radiación.

El proyecto comienza con una etapa de investigación del fenómeno físico. El estudiante deberá comprender qué fenómeno está estudiando, cuál es su fundamento físico, cuáles son las magnitudes involucradas, qué unidades utilizan, qué instrumentos, detectores, telescopios o misiones producen los datos y qué significado físico tiene cada variable. También deberá investigar la fuente científica de los datos, el periodo temporal que abarcan, el número aproximado de registros y las características generales del conjunto de datos. A partir de esta investigación deberá formular una pregunta científica que pueda ser abordada mediante el análisis computacional de los datos. Esta pregunta será el eje del proyecto y deberá orientar posteriormente la limpieza, las consultas a la base de datos, las visualizaciones y las conclusiones físicas.

Una vez comprendido el fenómeno, el estudiante deberá localizar y descargar los datos desde la fuente científica oficial asignada. Los datos deberán obtenerse inicialmente como un archivo plano, por ejemplo, CSV, TXT, TSV o ASCII. El archivo original deberá conservarse sin modificaciones como evidencia de la fuente de datos utilizada. El estudiante deberá documentar el origen del archivo, su dirección de consulta o descarga, la fecha de obtención, la información proporcionada por la fuente y la descripción de las variables contenidas. De esta manera se establecerá una separación entre los datos originales y los datos que posteriormente serán procesados.

Con los datos originales disponibles, el estudiante deberá utilizar JupyterLab para realizar una exploración inicial mediante Python y Pandas. En esta etapa deberá conocer la estructura del conjunto de datos, determinar el número de registros y variables, identificar los tipos de datos, reconocer variables numéricas y categóricas, estudiar los valores faltantes y duplicados, analizar los rangos de las variables, identificar valores atípicos y examinar las relaciones existentes entre las diferentes magnitudes físicas. Cuando los datos tengan una componente temporal, deberá analizarse también su evolución en el tiempo. El estudiante deberá generar visualizaciones que permitan comprender el comportamiento de los datos, tales como histogramas, series temporales, diagramas de dispersión, distribuciones y otras representaciones apropiadas al fenómeno estudiado. Esta etapa no debe limitarse a producir gráficas, sino que deberá interpretar qué información física puede observarse en ellas.

Posteriormente se realizará la limpieza y transformación de los datos. El estudiante deberá identificar problemas de calidad como valores faltantes, registros duplicados, errores de formato, unidades inconsistentes, datos imposibles desde el punto de vista físico, nombres inconsistentes, errores en fechas o variables que requieran transformación. Cada decisión de limpieza deberá estar justificada tanto desde el punto de vista computacional como desde el punto de vista físico. El estudiante deberá establecer qué registros se conservan, cuáles se transforman y cuáles se eliminan y explicar las razones correspondientes. El resultado de esta etapa será un nuevo conjunto de datos procesados que pueda utilizarse de manera confiable en las etapas posteriores. El archivo original nunca deberá ser sobrescrito, de modo que sea posible reconstruir y verificar todo el proceso de transformación.

A partir de los datos limpios, el estudiante deberá realizar el diseño de una base de datos relacional. Esta etapa implica pasar de la estructura de un archivo plano a una estructura organizada mediante entidades, atributos y relaciones. El estudiante deberá identificar qué elementos del fenómeno físico pueden convertirse en entidades, cuáles son sus atributos,

cuáles deben ser las claves primarias, cuáles serán las claves foráneas y cómo se relacionan las diferentes entidades. La información deberá organizarse de manera que se reduzca la redundancia y se garantice la integridad de los datos. No será suficiente con importar el archivo CSV como una única tabla; el estudiante deberá justificar la estructura relacional propuesta a partir de las características del problema científico.

Después del diseño conceptual se construirá el modelo entidad-relación completo. El estudiante deberá representar gráficamente las entidades, atributos, claves primarias, claves foráneas, relaciones y cardinalidades. Este modelo deberá elaborarse y visualizarse utilizando DBEaver, de manera que exista correspondencia entre el modelo conceptual y la implementación real de la base de datos. El diagrama completo generado en DBEaver formará parte de la evidencia del proyecto y deberá permitir comprender la arquitectura de la información científica almacenada.

Una vez definido el modelo, el estudiante deberá implementar la base de datos en MySQL. Deberá crear la base de datos, las tablas y todas las relaciones necesarias, definiendo correctamente los tipos de datos, claves primarias, claves foráneas y restricciones de integridad. La estructura completa deberá quedar documentada en un archivo SQL que permita reconstruir la base de datos desde cero. El estudiante deberá comprobar que las relaciones funcionan correctamente y que los datos pueden ser almacenados sin pérdida de información ni inconsistencias.

La base de datos deberá ejecutarse completamente contenerizada mediante Docker. El proyecto deberá disponer como mínimo de un contenedor para MySQL y un contenedor para JupyterLab, ambos conectados mediante una misma red Docker. MySQL deberá utilizar un volumen para garantizar la persistencia de la información, de manera que los datos no desaparezcan cuando el contenedor sea detenido o eliminado. La configuración del entorno deberá quedar definida mediante Docker Compose, permitiendo que otra persona pueda reconstruir el sistema utilizando la configuración entregada por el estudiante.

Desde el contenedor de JupyterLab, el estudiante deberá establecer una conexión con MySQL utilizando Python y las herramientas correspondientes, como SQLAlchemy y Pandas. La conexión deberá realizarse utilizando la red interna de Docker y el nombre del servicio de MySQL, demostrando que los contenedores pueden comunicarse entre sí. Desde JupyterLab deberá ser posible consultar las tablas de la base de datos, recuperar información mediante consultas SQL, procesarla con Pandas y utilizar los resultados para continuar el análisis científico.

El proceso de incorporación de los datos a MySQL deberá realizarse mediante un procedimiento reproducible de extracción, transformación y carga. El estudiante deberá leer el archivo plano mediante Python, aplicar las transformaciones y procesos de limpieza desarrollados previamente y posteriormente cargar la información en las diferentes tablas de la base de datos. No se permitirá realizar la carga completa de los datos mediante la digitación o inserción manual de registros. El proceso deberá estar automatizado mediante código para que pueda ejecutarse nuevamente en caso de reconstruir la base de datos.

Una vez poblada la base de datos, el estudiante deberá desarrollar consultas SQL que permitan explorar y analizar la información almacenada. Se deberán construir consultas de diferente nivel de complejidad, comenzando con consultas básicas y avanzando hacia agrupamientos, funciones estadísticas, combinaciones de tablas mediante JOIN, subconsultas, condiciones, clasificación de resultados y otras operaciones pertinentes. Una parte importante de las consultas deberá estar directamente relacionada con la pregunta científica planteada al comienzo del proyecto. De esta manera, SQL no será utilizado solamente para demostrar conocimientos sintácticos, sino como una herramienta para obtener información científicamente relevante a partir de la base de datos.

Los resultados obtenidos mediante SQL deberán integrarse nuevamente con Python para realizar el análisis científico. El estudiante deberá seleccionar los resultados relevantes, construir tablas y visualizaciones y realizar una interpretación física de los patrones encontrados. Deberá explicar qué comportamiento se observa, qué relaciones existen entre las variables, qué resultados son significativos y cómo estos resultados permiten responder la pregunta científica planteada inicialmente. El análisis deberá establecer una conexión clara entre los datos, las consultas realizadas y el fenómeno físico.

DBeaver tendrá además un papel fundamental en la administración y validación de la base de datos. El estudiante deberá utilizarlo para conectarse al servidor MySQL, visualizar las tablas, comprobar las claves primarias y foráneas, ejecutar consultas SQL y generar el esquema completo de la base de datos. El diagrama generado mediante DBeaver deberá mostrar de manera integral la estructura relacional construida y deberá coincidir con la implementación realizada en MySQL. El estudiante deberá demostrar que puede administrar y explorar la base de datos tanto mediante código desde JupyterLab como mediante una herramienta gráfica de gestión de bases de datos.

Al finalizar el proyecto, el estudiante deberá disponer de un sistema reproducible en el que sea posible partir del archivo científico original, ejecutar el proceso de exploración y limpieza mediante JupyterLab, transformar los datos, construir y poblar una base de datos relacional MySQL, ejecutar el servidor dentro de Docker, conectar JupyterLab y MySQL mediante una red Docker, conservar los datos mediante un volumen persistente, consultar la información desde DBeaver y utilizar SQL y Python para responder una pregunta científica. El proyecto deberá demostrar, por tanto, la integración entre conocimiento físico, análisis de datos, programación, bases de datos y tecnologías de contenedores.

La entrega final deberá contener el archivo de datos original, los datos procesados, los notebooks utilizados para la exploración, limpieza, transformación y análisis, el archivo SQL con la estructura de la base de datos y las consultas desarrolladas, el modelo entidad-relación generado en DBeaver, la configuración Docker Compose, las dependencias necesarias, la documentación del proyecto y un informe final con la interpretación científica de los resultados. Toda la estructura deberá estar organizada de manera que otra persona pueda descargar el proyecto, levantar los contenedores y reproducir el procedimiento.

Durante la sustentación el estudiante deberá demostrar el funcionamiento completo del sistema. Deberá levantar los contenedores mediante Docker Compose, comprobar que MySQL y JupyterLab se encuentran activos y conectados a la misma red, acceder a

JupyterLab, ejecutar el código de conexión y realizar consultas sobre la base de datos, abrir la base de datos mediante DBeaver, mostrar las tablas y relaciones, presentar el esquema completo generado en DBeaver, ejecutar algunas de las consultas SQL desarrolladas y mostrar las gráficas y resultados obtenidos. La sustentación deberá finalizar con la explicación física de los resultados y la respuesta a la pregunta científica planteada al inicio.

El producto final deberá evidenciar que el estudiante no solamente sabe descargar y analizar un conjunto de datos, sino que es capaz de transformar datos científicos reales en un sistema de información estructurado, reproducible y funcional, integrando Física, Python, Pandas, SQL, MySQL, DBeaver, JupyterLab y Docker en un único proyecto.

Criterio	Excelente	Bueno	Básico	Insuficiente	Puntos
1. Investigación y fundamentación física	Explica con rigor el fenómeno, variables, unidades, instrumentos y contexto científico; plantea una pregunta física clara y pertinente.	Explica correctamente el fenómeno y sus variables; la pregunta es pertinente.	Presenta una explicación general con algunas imprecisiones o una pregunta poco desarrollada.	No demuestra comprensión del fenómeno o no plantea una pregunta científica.	10
2. Obtención y documentación de los datos	Utiliza una fuente científica oficial, descarga datos reales en archivo plano y documenta origen, periodo, variables y metodología de obtención.	Fuente oficial y datos correctamente obtenidos y documentados.	Fuente o documentación incompleta.	Datos sin procedencia verificable o inexistentes.	8
3. Exploración y análisis inicial con Python/Pandas	Realiza exploración completa, identifica estructura, tipos, faltantes, duplicados, estadísticos y relaciones; genera e interpreta visualizaciones científicas.	Realiza correctamente la exploración y presenta visualizaciones pertinentes.	Exploración parcial o con análisis limitado.	Exploración mínima, incorrecta o inexistente.	10
4. Limpieza y transformación de datos	Identifica problemas de calidad, aplica transformaciones reproducibles y justifica las decisiones desde criterios computacionales y físicos.	Limpia y transforma correctamente los datos.	Realiza limpieza básica pero con poca justificación.	Datos sin limpiar o proceso incorrecto/no reproducible.	12
5. Diseño del modelo relacional	Identifica correctamente entidades, atributos, PK, FK y relaciones; presenta un modelo normalizado y	Modelo relacional correcto con pequeñas inconsistencias.	Modelo parcialmente normalizado o con relaciones poco justificadas.	Modelo incorrecto o simplemente convierte el archivo plano en una tabla.	12

	coherente con el fenómeno y los datos.				
6. Implementación de MySQL	Implementa completamente la BD, con tipos de datos, PK, FK, restricciones e integridad referencial; el <code>schema.sql</code> permite reconstruirla.	BD funcional con estructura adecuada y pocos errores.	BD funcional pero con deficiencias estructurales.	BD incompleta o no funcional.	10
7. Integración Python–MySQL–JupyterLab	La conexión funciona correctamente; Python puede consultar, cargar y recuperar datos de MySQL de manera reproducible.	Integración funcional con pequeños problemas.	Conexión parcialmente funcional o dependiente de procesos manuales.	No existe integración funcional.	8
8. Docker y arquitectura del sistema	MySQL y JupyterLab funcionan en contenedores, comparten una red, MySQL utiliza volumen persistente y todo se reconstruye mediante Docker Compose.	Arquitectura funcional con pequeñas deficiencias.	Contenedores funcionan pero falta algún elemento de la arquitectura.	No logra una implementación funcional en Docker.	12
9. SQL y análisis científico	Desarrolla consultas de diferente complejidad, incluyendo JOIN, agrupamientos, subconsultas u operaciones avanzadas; las utiliza para responder preguntas físicas.	Presenta consultas correctas y algunas preguntas científicas.	Predominan consultas básicas con poca interpretación.	Consultas insuficientes, incorrectas o sin relación con el problema físico.	10
10. DBeaver y esquema completo	Conecta correctamente a MySQL, administra la BD, ejecuta consultas y presenta el esquema ER completo y coherente.	Utiliza DBeaver correctamente y presenta el esquema.	Uso limitado o esquema incompleto.	No demuestra manejo de DBeaver o no presenta el esquema.	4

11. Documentación, reproducibilidad y sustentación	Proyecto organizado, código documentado, README completo y sistema reproducible; explica y defiende técnicamente las decisiones tomadas.	Buena documentación y sustentación.	Documentación o sustentación parcial.	Proyecto desorganizado, no reproducible o no puede explicar su funcionamiento.	4
				TOTAL	100